

Lab 1: Tổng quan Khoa học Dữ liệu và SQL

Lương Anh Đức — MSV: PH67826.




Bài 1 – Vai trò của Khoa học Dữ liệu tại Shopee



Phân tích hành vi & dự đoán nhu cầu

Với hàng triệu người dùng và sản phẩm, KHDL giúp hiểu chuỗi hành vi (view → add-to-cart → purchase), phát hiện pattern theo nhóm khách hàng và dự báo nhu cầu theo mùa/chiến dịch.



Tối ưu chiến lược marketing

Phân tích chiến dịch (ROI, conversion funnel), tối ưu hoá ngân sách quảng cáo và cá nhân hoá nội dung hiển thị giúp tăng hiệu suất chi tiêu marketing.



Tối ưu vận hành & logistics

Dự đoán nhu cầu tồn kho, tối ưu định tuyến giao hàng và giảm thời gian giao nhận — tất cả dựa trên mô hình dữ liệu lịch sử và sự kiện thời gian thực.

Tóm lại, KHDL chuyển dữ liệu thô thành quyết định có thể hành động: tăng chuyển đổi, giảm chi phí và cải thiện trải nghiệm người dùng.

Bài toán ứng dụng – Gợi ý sản phẩm & Phát hiện gian lận

Bài toán 1: Tối ưu hệ thống gợi ý sản phẩm

Mục tiêu: Hiển thị chính xác sản phẩm khách hàng quan tâm ngay khi mở app, giảm thời gian tìm kiếm và tăng tỉ lệ chuyển đổi.
Phương pháp KHD: kết hợp Collaborative Filtering, Content-based Filtering và mô hình học sâu (embedding sản phẩm, user behavior sequences). Dữ liệu đầu vào gồm lịch sử xem, giỏ hàng, mua hàng, dấu hiệu tương tác (dwell time, clicks). Lợi ích: Tăng AOV (Average Order Value), CR (Conversion Rate) và thời gian tương tác trung bình.

Bài toán 2: Phát hiện gian lận khuyến mãi

Mục tiêu: Ngăn chặn tài khoản ảo, bot, và hành vi thao túng mã giảm giá. Phương pháp KHD: xây dựng hệ phát hiện bất thường (anomaly detection) và mô hình phân loại (supervised / semi-supervised) kết hợp feature engineering (IP reuse, device fingerprint, shipping address clusters, order velocity). Lợi ích: Bảo vệ ngân sách khuyến mãi, nâng cao chất lượng dữ liệu người dùng thật và giảm rủi ro vận hành.

Vai trò của SQL trong Khoa học Dữ liệu

SQL là công cụ nền tảng để trích xuất, làm sạch và tiền xử lý dữ liệu trước khi đưa vào mô hình. Thay vì chạy mô hình trên toàn bộ kho dữ liệu hàng tỷ dòng, SQL giúp:

- Trích xuất tập dữ liệu đại diện (sampling, time-window filtering).
- Làm giàu dữ liệu (joins giữa user, order, product_view, product).
- Tạo các feature cơ bản: số lượt xem trong 30 ngày, tần suất mua, thời gian giữa các giao dịch, tỉ lệ hoàn trả.
- Áp dụng ràng buộc, kiểm tra tính toàn vẹn ngay ở tầng truy vấn để tránh dữ liệu nhiễu.



Bảng user

Thông tin nhân khẩu học: tuổi, giới tính, tỉnh thành — dùng để phân luồng gợi ý theo phân khúc.



Bảng order

Danh sách đơn hàng thành công trong 6 tháng — nguồn ground-truth cho mô hình recommendation và churn analysis.



Bảng product_view

Lưu lượt xem, thêm giỏ hàng nhưng chưa mua — tín hiệu ý định (intent) quan trọng cho ranking.



Bảng product

Thông tin ngành hàng, giá, rating — để gán nhãn nội dung và lựa chọn sản phẩm ưu tiên hiển thị.

Bài 2 – Phân loại dữ liệu & Lựa chọn hệ quản trị

Phân loại cơ bản:


- **Dữ liệu có cấu trúc (Structured):** bảng, cột, kiểu dữ liệu cố định — dễ lưu trữ và truy vấn (ví dụ: A và D trong bài tập).
- **Dữ liệu phi cấu trúc (Unstructured):** văn bản tự do, hình ảnh, log, nhiều nhiều — cần pipeline xử lý đặc thù (ví dụ: B và C).

Vì sao A và D phù hợp với RDBMS (PostgreSQL)?

1. Schema cố định giúp đảm bảo tính nhất quán và dễ truy vấn bằng SQL.
2. RDBMS mạnh về liên kết các thực thể (JOINS) để kết hợp user-order-product một cách hiệu quả.
3. Ràng buộc (constraints), transaction ACID đảm bảo toàn vẹn tài chính (không cho phép số âm, duplicate IDs...).

Bài 3 – Các bước xây dựng hệ thống gợi ý sản phẩm

1. **Thu thập dữ liệu (Data Collection):** Lưu trữ lịch sử tương tác người dùng (view, click, add-to-cart, purchase) cùng metadata sản phẩm (category, price, rating). Dữ liệu này được lưu trong các bảng user, product, order, product_view.
2. **Xử lý & làm sạch dữ liệu (Data Preprocessing):** Loại bỏ dữ liệu trùng lặp, xử lý giá trị thiếu, chuẩn hoá các trường (ví dụ: giá tiền, rating). Sử dụng SQL để trích xuất tập dữ liệu đại diện và tạo các feature cơ bản.
3. **Kỹ thuật gợi ý (Recommendation Techniques):**
 - **Collaborative Filtering:** Tìm người dùng tương tự dựa trên lịch sử mua hàng, sau đó gợi ý sản phẩm mà họ đã mua nhưng bạn chưa.
 - **Content-based Filtering:** So sánh đặc tính sản phẩm (category, price range, rating) với những sản phẩm người dùng đã yêu thích.
 - **Hybrid Approach:** Kết hợp cả hai phương pháp để tăng độ chính xác.
4. **Huấn luyện mô hình (Model Training):** Sử dụng các thuật toán như Matrix Factorization, Neural Networks hoặc Gradient Boosting để học pattern từ dữ liệu lịch sử. Chia dữ liệu thành train/validation/test set để đánh giá hiệu năng.
5. **Đánh giá & tối ưu (Evaluation & Optimization):** Sử dụng các metric như Precision@K, Recall@K, NDCG để đo lường chất lượng gợi ý. Thực hiện A/B testing trên người dùng thực để so sánh hiệu suất các phiên bản mô hình khác nhau.



Bài 4 – Công cụ quản trị PostgreSQL (pgAdmin)

Hình ảnh minh họa: giao diện pgAdmin hiển thị dashboard, tree schema và bảng dữ liệu.

Trực quan hoá cấu trúc & dữ liệu

pgAdmin hiển thị cây thư mục database, bảng, cột và ràng buộc giống như đọc file Excel — giúp người dùng mới và phân tích nhanh mà không cần ghi toàn bộ câu lệnh.

Hỗ trợ viết code thông minh

Query Tool với autocomplete, highlight và execution plan giúp soạn thảo truy vấn nhanh hơn, kiểm tra hiệu năng và sửa lỗi dễ dàng.

Quản trị & giám sát

Dashboard tích hợp cung cấp metrics (kết nối, transactions/sec, I/O), sao lưu/phục hồi, phân quyền — giảm thời gian quản lý hệ thống.

Kết luận

Tổng kết:

- Khoa học Dữ liệu là nhân tố then chốt giúp khai thác dữ liệu thành quyết định kinh doanh đúng đắn.
- SQL là công cụ thiết yếu để trích xuất, làm sạch và chuẩn hoá dữ liệu trước khi phân tích hoặc huấn luyện mô hình.
- Lựa chọn hệ quản trị (PostgreSQL vs BigQuery) phụ thuộc vào yêu cầu về transaction, quy mô dữ liệu và mục tiêu phân tích.

Đề xuất bước tiếp theo cho sinh viên: - Thực hành viết truy vấn SQL để xây dựng feature pipelines (window functions, CTEs). - Xây dựng một prototype hệ gợi ý (collaborative + content-based) trên tập dữ liệu giả lập. - Thử nghiệm mô hình phát hiện gian lận với dữ liệu synthetic, triển khai monitoring cho model drift.